

메타의 MUSE에서는 DRAM (VM)은

현재

8GB 할당 / ~3GB 사용

↓

고도화

16GB 할당 / 6~10GB 사용

↓

복잡한 Agent

32GB+ 할당 / 10~20GB+ 사용 처럼 올라갈 가능성이 있습니다.

이 부분이 DRAM 업체 입장에서 진짜 중요한 옵션입니다.

결론

현재 Agent의 DRAM 효과는 "8GB × Agent 수"가 아니라

"실제 평균 3GB 안팎 × 동시 활성화 Agent 수"로 봐야 하고,

향후 Agent가 고도화되면서 3GB → 8GB → 16GB로 올라가는
것이 DRAM 수요의 추가적인 업사이드입니다.

=====

=====

MUSE에서 메모리는

Muse의 VM (Virtual Machine)은 새로운 기술이 아니라 기존 VM을 '개인 AI마다 상시 존재하는 컴퓨터'로 사용하는 변화이며, 이 변화의 메모리 수혜는 1차적으로 서버 DRAM, 2차적으로 CXL/SSD·NAND로 보는 것이 맞습니다.

Meta가 공식적으로 밝힌 Muse Secure VM은 지속적으로 존재하는(persistent) 격리된 Linux 컴퓨터이고,

여기에 CPU·memory·storage·browser가 붙습니다. 즉 단순한 서버 프로세스가 아니라

사실상 사용자마다 하나의 작은 컴퓨터를 할당하는 개념입니다.

사용자 → AI Agent → 사용자별 VM(가상 컴퓨터) → CPU + DRAM + SSD

VM 자체는 전혀 새로운 기술이 아닙니다.

AWS, Azure, Google Cloud 등에서 오래전부터 사용해온 기술입니다.

다만 AI Agent의 대중화와 함께 VM의 용도가 달라지는 것이 중요합니다

VM 하나가 독립적인 컴퓨터처럼 작동하려면

CPU + DRAM + Storage가 필요합니다.

특히 Agent가 장시간 작업하면 다음이 동시에 메모리에 올라감

니다.

- AI Agent의 실행 상태
- 브라우저
- 웹페이지
- 여러 애플리케이션
- 대화/context
- 여러 sub-agent
- 작업 중간 결과
- 인증·세션 정보
- 각종 프로세스

따라서 사용자 1명당 필요한 RAM이 기존 chatbot 사용자보다 커질 가능성이 있습니다.

더 중요한 것은 Meta가 Muse를 수억~수십억 명에게 확장 가능한 personal agent로 설계한다는 점입니다.

일단 단순화하면 $\text{Agent 수} \times \text{Agent당 RAM}$ 이 새로운 DRAM 수요 공식이 될 수 있습니다.

	일반 ChatGPT	Muse Agent
사용자별 독립 VM	×	O
사용자별 시스템 RAM	별도 VM 없음	약 8GB
CPU	요청 시 서버 공유	2 vCPU 수준
Browser	필요 시	상시 VM에 존재
Storage	일반 서비스 인프라	약 100GB VM storage
AI 모델 메모리	GPU/HBM/서버 DRAM	별도
작업 지속성	상대적으로 낮음	상시/백그라운드

현재 Agent의 DRAM 효과는 "8GB × Agent 수"가 아니라 "실제 평균 3GB 안팎 × 동시 활성화 Agent 수"로 봐야 하고,

향후 Agent가 고도화되면서 3GB → 8GB → 16GB로 올라가는 것이 DRAM 수요의 추가적인 업사이드입니다.

8GB는 '모델을 담아두는 RAM'이 아니라, AI 모델(Muse Spark)이 에이전트로 실제 일을 수행할 때 사용하는 '사용자별 가상 컴퓨터의 시스템 RAM'

Meta가 설명하는 구조는 Muse Spark(LLM)와 Muse Secure VM(사용자별 실행 컴퓨터)를 구분해서 보는 게 핵심입니다. Muse의 VM에는 CPU·memory·storage가 있고, 그 안에서 브라우저를 열고 파일을 만들고 코드를 실행하고 여러 작업을 수행합

니다.

① AI 모델

Muse Spark

↓

판단·추론·"무엇을 해야 하는가" 결정

② 사용자별 VM

CPU + 약 8GB RAM + SSD

↓

브라우저 실행

이메일 열기

웹사이트 접속

파일 처리

코드 실행

작업 결과 저장

여러 sub-agent 작업

즉,

LLM = 두뇌

VM = 그 두뇌가 일을 수행할 수 있는 개인용 컴퓨터라고 생각
하시면 됩니다.

실제 사용자 환경에서 약 2 vCPU + 8GB RAM + 100GB storage
가 관찰됐습니다.

다만 이 8GB는 Meta가 공식적으로 모든 사용자에게 보장한다고 발표한 사양은 아닙니다.

또 $8\text{GB} \times \text{사용자 수} = \text{실제 DRAM 출하량}$ 으로 바로 계산하면 안 됩니다.

VM의 8GB는 논리적 할당량이고 실제 물리 DRAM 사용량은 공유·overcommit·메모리 회수 등에 따라 더 작을 수 있습니다.

현재:

$\text{Agent 1개} \times 8\text{GB} = 8\text{GB의 VM 메모리 capacity}$

Agent가 100개로 늘어나면:

$\text{Agent 100개} \times 8\text{GB} = 800\text{GB의 VM 메모리 capacity}$

따라서 다른 조건이 동일하고, 100개 VM이 동시에 실제로 8GB 씩 물리 DRAM을 점유한다면 DRAM 필요량도 100배가 맞습니다.

그런데 왜 "100배라고 보면 안 된다"?

8GB가 '논리적 할당량'인지 '실제 물리 DRAM 점유량'인지가 다르기 때문입니다.

예를 들어 데이터센터가:

$\text{VM 100개} \times 8\text{GB} = 800\text{GB}$ 로 설정해 놓았더라도,

실제로 각 VM이 평균 2GB만 사용한다면

실제 물리 DRAM 사용량 $\approx 200\text{GB}$ 일 수 있습니다.

또 여러 VM의 메모리를 효율적으로 관리하거나 일부 작업을 SSD로 넘기면 실제 필요 DRAM은 더 줄어들 수 있습니다.

실제 DRAM 출하량 증가폭은 VM당 8GB 중 실제 평균 사용량과 데이터센터의 메모리 오버커밋·공유 효율에 따라 결정됩니다.

: 메모리 오버커밋=각 VM에게 8GB까지 쓸 수 있다고 약속하지만, 실제로는 모든 VM이 동시에 8GB를 쓰지는 않는다는 것을 이용하는 것"

따라서 투자 관점에서 중요한 것은 Agent 수 $\times$ Agent당 실제 평균 DRAM 사용량입니다.

8GB를 할당받았지만 실제 사용은 약 3GB

실제 Muse VM을 조사한 결과:

- VM에 보이는 메모리: 약 7.7~8GB
- 실제 측정된 메모리 사용량: 약 3GB
- 즉 8GB를 전부 물리 DRAM으로 항상 점유하는 것은 아님

따라서 현재 단계에서는 Agent 1개당 실제 DRAM 사용량을 약 3GB 수준으로 보는 관측 사례가 있습니다.

CPU와 DRAM은 오버커밋 정도가 다릅니다. 이게 중요합니다.

CPU

Agent가 가만히 있을 때:

CPU 사용량 $\approx$ 거의 0이 가능합니다.

따라서 100개 Agent $\rightarrow$ 물리 CPU 몇 개 로 상당히 많이 공유할 수 있습니다.

DRAM

Agent가 작업하지 않는다고 해도 현재 작업 상태는 메모리에 남아 있어야 합니다.

따라서 CPU보다 DRAM은 공유하기가 어렵습니다.

실제로 Muse 관련 분석에서도 CPU는 상당히 공격적으로 oversubscribe할 수 있지만 **memory는 live VM의 working state를 유지해야 하므로 훨씬 어렵다고** 지적합니다

===이제 진짜 중요한 부분입니다===

3GB가 미래에도 3GB일 것인가? 아닐 가능성이 높다고 봅니다.

Agent가 고도화되면:

- 브라우저 여러 개
- 파일/문서
- Python 실행

- 코드 개발
- 이미지 생성/편집
- 여러 sub-agent
- 긴 context
- local memory
- 장시간 작업 등이 증가합니다.

실제로 OpenAI의 dots 환경은 최근 관찰상 약 9.73GB RAM을 가진 VM으로 나타났습니다. Muse의 약 8GB보다도 높은 수준입니다.

따라서

메타의 MUSE에서는 DRAM (VM)은

현재

8GB 할당 / ~3GB 사용

↓

고도화

16GB 할당 / 6~10GB 사용

↓

복잡한 Agent

32GB+ 할당 / 10~20GB+ 사용 처럼 올라갈 가능성이 있습니다.

이 부분이 DRAM 업체 입장에서 진짜 중요한 옵션입니다.

결론

현재 Agent의 DRAM 효과는 "8GB × Agent 수"가 아니라

"실제 평균 3GB 안팎 × 동시 활성화 Agent 수"로 봐야 하고,

향후 Agent가 고도화되면서 3GB → 8GB → 16GB로 올라가는 것이 DRAM 수요의 추가적인 업사이드입니다.

또한, Muse Secure VM에는 각 사용자에게 storage가 존재합니다. Meta도 VM을 "storage, CPU and memory to handle real work"를 갖춘

컴퓨터라고 설명합니다.

예를 들어 개인 Agent가 계속 사용자의

- 이메일/첨부파일
- 문서
- 브라우저 데이터
- 작업 기록
- agent memory
- 생성한 파일

- 이미지/영상
- 애플리케이션 데이터

등을 축적하면 SSD/NAND storage 수요도 증가합니다.

그래서 구조를 단순화하면:

AI Agent 확산

→ 사용자별 VM 증가

→ CPU 증가

→ DRAM 증가

→ SSD/NAND 증가

→ 네트워크 증가입니다.

기존 클라우드 VM도 이미 많습니다.

그런데 Agent는 사용자가 질문할 때만 계산하는 것이 아니라

사용자가 자고 있어도 목표를 추적하고 → 웹을 검색하고 → 가격을 비교하고 → 예약 가능 여부를 확인하고 → 변화가 생기면 다시 실행

할 수 있습니다.

Meta도 Muse가 앱을 닫은 뒤에도 백그라운드에서 계속 작업한다고 명시하고 있습니다.

따라서 평균 CPU utilization과 평균 메모리 점유시간이 증가할

가능성이 있습니다.